

# 信息学中的概率统计

王若松

前沿计算研究中心  
北京大学

# 参数估计

1. 统计学的基本概念
2. 点估计
3. 区间估计

# 1. 统计学的基本概念

- ▶ 概率论：假设概率分布已知
- ▶ 统计学：利用观察到的数据，推断出数据背后的分布的性质
- ▶ 例：给定广告的点击数据，如何估计广告的平均点击率？
- ▶ **总体**：研究对象的全体
- ▶ **个体**：总体的每个成员
- ▶ 通常只关心个体的数量指标值
  - ▶ 用概率分布描述总体，数量指标值为服从该分布的随机变量 $X$

# 1. 统计学的基本概念

- ▶ 从总体中随机地抽取 $n$ 个个体 $x_1, x_2, \dots, x_n$
- ▶ **样本**:  $x_1, x_2, \dots, x_n$
- ▶ **样本量**:  $n$
- ▶ 样本是随机变量, 也写作 $X_1, X_2, \dots, X_n$ ,  $X_i$ 与总体 $X$ 分布相同
- ▶ **简单随机样本**:  $X_1, X_2, \dots, X_n$ 相互独立, 且均服从与总体 $X$ 相同的分布
- ▶ 若 $X$ 的分布函数为 $F(x)$ , 样本的联合分布函数为 $F(x_1, x_2, \dots, x_n) = \prod_{i=1}^n F(x_i)$
- ▶ 统计学: 利用样本 $x_1, x_2, \dots, x_n$ , 研究总体 $X$ 的性质

# 1. 统计学的基本概念

- ▶ **统计量**：不依赖于任何未知参数的样本的函数
- ▶ 样本均值：  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$
- ▶ 样本方差：  $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$
- ▶  $k$ 阶矩：  $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$
- ▶  $k$ 阶中心矩：  $B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$
- ▶ 其他统计量：  $\min\{X_1, X_2, \dots, X_n\}$  ,  $\max\{X_1, X_2, \dots, X_n\}$  , 中位数

## 2. 点估计

- ▶ **点估计**：估计分布中所含有的未知参数 $\theta$ ，如 $\theta = E(X)$ 和 $\theta = \text{Var}(X)$
- ▶ 例：给定广告的点击数据，如何估计广告的平均点击率？
  - ▶ 给定样本 $x_1, x_2, \dots, x_n$ ，如何估计 $\theta = E(X)$ ？
- ▶ **估计量**：用来估计未知参数 $\theta$ 的统计量 $\hat{\theta}(X_1, X_2, \dots, X_n)$
- ▶ **估计值**：给定样本取值 $x_1, x_2, \dots, x_n$ ， $\hat{\theta}(x_1, x_2, \dots, x_n)$ 为估计值
- ▶ 如何评判估计量的好坏？

## 2. 点估计

- ▶ 已知总体 $X$ 数学期望 $E(X)$ 和方差 $\text{Var}(X)$ 均存在
- ▶ 考虑 $\theta = E(X)$ 的下述估计量
- ▶  $\hat{\theta}_A(X_1, X_2, \dots, X_n) = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$
- ▶  $\hat{\theta}_B(X_1, X_2, \dots, X_n) = X_1$
- ▶  $\hat{\theta}_C(X_1, X_2, \dots, X_n) = \frac{1}{n+1} \sum_{i=1}^n X_i$
- ▶ 哪个估计量最好?

## 2. 点估计

- ▶ 给定参数 $\theta$ 的估计量 $\hat{\theta}(X_1, X_2, \dots, X_n)$ , 定义**偏差** $\text{Bias}(\hat{\theta}) = E(\hat{\theta}) - \theta$
- ▶ 如果 $\text{Bias}(\hat{\theta}) = 0$ , 则称估计量 $\hat{\theta}$ 是**无偏的**
- ▶ 当 $n = 1$ 时
- ▶  $\hat{\theta}_A = \hat{\theta}_B = X_1, \quad \hat{\theta}_C = \frac{1}{2}X_1$
- ▶  $E(X_1) = E(X)$
- ▶ 如果 $\lim_{n \rightarrow \infty} E(\hat{\theta}) = \theta$ , 则称估计量 $\hat{\theta}$ 是**渐进无偏的**



## 2. 点估计

- ▶ 已知总体 $X$ 数学期望 $E(X)$ 和方差 $\text{Var}(X)$ 均存在, 考虑 $\theta = E(X)$ 的下述估计量
- ▶  $\hat{\theta}_A(X_1, X_2, \dots, X_n) = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$
- ▶  $\hat{\theta}_B(X_1, X_2, \dots, X_n) = X_1$
- ▶ 给定参数 $\theta$ 的估计量 $\hat{\theta}$ , 定义**均方误差** $\text{MSE}(\hat{\theta}) = E \left( (\hat{\theta} - \theta)^2 \right)$
- ▶ 若估计量 $\hat{\theta}$ 无偏, 则 $\text{MSE}(\hat{\theta}) = \text{Var}(\hat{\theta})$ 
  - ▶  $\text{MSE}(\hat{\theta}) = E \left( (\hat{\theta} - \theta)^2 \right) = E \left( (\hat{\theta} - E(\hat{\theta}))^2 \right) = \text{Var}(\hat{\theta})$

## 2. 点估计

- ▶ 已知总体 $X$ 数学期望 $E(X)$ 和方差 $\text{Var}(X)$ 均存在, 考虑 $\theta = E(X)$ 的下述估计量
- ▶  $\hat{\theta}_A(X_1, X_2, \dots, X_n) = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$
- ▶  $\hat{\theta}_B(X_1, X_2, \dots, X_n) = X_1$
  
- ▶ 给定参数 $\theta$ 的估计量 $\hat{\theta}$ , 定义**均方误差** $\text{MSE}(\hat{\theta}) = E((\hat{\theta} - \theta)^2)$
- ▶ 若估计量 $\hat{\theta}$ 无偏, 则 $\text{MSE}(\hat{\theta}) = \text{Var}(\hat{\theta})$
- ▶ 计算 $\hat{\theta}_A$ 和 $\hat{\theta}_B$ 的均方误差
  - ▶  $\text{MSE}(\hat{\theta}_A) = \text{Var}(\hat{\theta}_A) = \text{Var}(X)/n$
  - ▶  $\text{MSE}(\hat{\theta}_B) = \text{Var}(\hat{\theta}_B) = \text{Var}(X)$

## 2. 点估计

- ▶ 给定参数 $\theta$ 的估计量 $\hat{\theta}_n = \hat{\theta}_n(X_1, X_2, \dots, X_n)$ , 若有 $\hat{\theta}_n \xrightarrow{P} \theta$ , 也即对于任意 $\epsilon > 0$ ,  
 $\lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| \geq \epsilon) = 0$ , 则称估计量  $\hat{\theta}_n$  为**一致估计量**
- ▶  $\hat{\theta}_A(X_1, X_2, \dots, X_n) = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$
- ▶  $\hat{\theta}_B(X_1, X_2, \dots, X_n) = X_1$
- ▶  $\hat{\theta}_C(X_1, X_2, \dots, X_n) = \frac{1}{n+1} \sum_{i=1}^n X_i$
- ▶ 哪个估计量是一致的?

## 2. 点估计

- ▶ 若  $\lim_{n \rightarrow \infty} \text{MSE}(\hat{\theta}_n) \rightarrow 0$ , 则  $\hat{\theta}_n$  为一致估计量
  - ▶ 对于任意  $\epsilon > 0$ ,  $P(|\hat{\theta}_n - \theta| \geq \epsilon) = P((\hat{\theta}_n - \theta)^2 \geq \epsilon^2) \leq \text{MSE}(\hat{\theta}_n)/\epsilon^2$
  - ▶ 左右两侧取极限即可
- ▶ 有偏估计量是否为一致估计量?
- ▶ 渐进无偏估计量是否为一致估计量?
- ▶ 一致估计量是否为渐进无偏估计量?

## 2. 点估计

- ▶ 令总体  $X \sim U(0, \theta)$
- ▶ 判断估计量  $\hat{\theta}_A = 2\bar{X}$  和  $\hat{\theta}_B = \max\{X_1, X_2, \dots, X_n\}$  的无偏性
- ▶  $E(\hat{\theta}_A) = 2 \cdot E(X) = \theta$
- ▶  $F_{\hat{\theta}_B}(x) = (F_X(x))^n = \left(\frac{x}{\theta}\right)^n$  当  $0 \leq x \leq \theta$
- ▶  $E(\hat{\theta}_B) = \int_0^{+\infty} (1 - F(x)) dx = \int_0^\theta \left(1 - \left(\frac{x}{\theta}\right)^n\right) dx = \frac{n}{n+1} \theta$
- ▶  $\hat{\theta}_B$  渐进无偏
- ▶  $\hat{\theta}_C = \max\{X_1, X_2, \dots, X_n\} \cdot \frac{n+1}{n}$  是无偏估计量

## 2. 点估计

- ▶ 令总体  $X \sim U(0, \theta)$ , 比较  $\hat{\theta}_A = 2\bar{X}$  和  $\hat{\theta}_C = \max\{X_1, X_2, \dots, X_n\} \cdot \frac{n+1}{n}$  的均方误差
- ▶  $\text{MSE}(\hat{\theta}_A) = \text{Var}(\hat{\theta}_A) = \frac{\text{Var}(2X)}{n} = \frac{\theta^2}{3n}$

## 2. 点估计

- ▶ 令总体  $X \sim U(0, \theta)$ , 比较  $\hat{\theta}_A = 2\bar{X}$  和  $\hat{\theta}_C = \max\{X_1, X_2, \dots, X_n\} \cdot \frac{n+1}{n}$  的均方误差
- ▶  $\hat{\theta}_B = \max\{X_1, X_2, \dots, X_n\}$
- ▶  $F_{\hat{\theta}_B}(x) = (F_X(x))^n = \left(\frac{x}{\theta}\right)^n$  当  $0 \leq x \leq \theta$
- ▶  $F_{\hat{\theta}_B^2}(x) = F_{\hat{\theta}_B}(\sqrt{x}) = \frac{x^{\frac{n}{2}}}{\theta^n}$  当  $0 \leq x \leq \theta^2$
- ▶  $E(\hat{\theta}_B^2) = \int_0^{\theta^2} \left(1 - \frac{x^{\frac{n}{2}}}{\theta^n}\right) dx = \frac{n}{n+2} \theta^2$
- ▶  $\text{Var}(\hat{\theta}_B^2) = \frac{n}{n+2} \theta^2 - \left(\frac{n}{n+1} \theta\right)^2$
- ▶  $\text{MSE}(\hat{\theta}_C) = \text{Var}(\hat{\theta}_C) = \left(\frac{n+1}{n}\right)^2 \cdot \text{Var}(\hat{\theta}_B^2) = \frac{\theta^2}{n(n+2)}$

## 2. 点估计

- ▶ 令总体  $X \sim U(0, \theta)$ , 比较  $\hat{\theta}_A = 2\bar{X}$  和  $\hat{\theta}_C = \max\{X_1, X_2, \dots, X_n\} \cdot \frac{n+1}{n}$  的均方误差
- ▶  $\text{MSE}(\hat{\theta}_A) = \frac{\theta^2}{3n}$
- ▶  $\text{MSE}(\hat{\theta}_C) = \frac{\theta^2}{n(n+2)}$
- ▶  $\hat{\theta}_A$  和  $\hat{\theta}_C$  是否为一致估计量?



## 2. 点估计

- ▶  $k$ 阶矩:  $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$
- ▶  $k$ 阶中心矩:  $B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$
- ▶  $A_k$ 是否为  $E(X^k)$  的无偏估计?
  - ▶  $E(A_k) = \frac{1}{n} \sum_{i=1}^n E(X_i^k) = E(X^k)$
- ▶  $B_2$ 是否为  $\text{Var}(X)$  的无偏估计?
  - ▶  $\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n (X_i^2 + \bar{X}^2 - 2X_i\bar{X}) = \sum_{i=1}^n X_i^2 - n\bar{X}^2$
  - ▶  $B_2 = A_2 - \bar{X}^2 \Rightarrow E(B_2) = E(X^2) - E(\bar{X}^2)$
  - ▶  $E(\bar{X}^2) = (E(\bar{X}))^2 + \text{Var}(\bar{X}) = (E(X))^2 + \frac{\text{Var}(X)}{n}$
  - ▶  $E(B_2) = \frac{n-1}{n} \cdot \text{Var}(X)$

## 2. 点估计

- ▶  $E(B_2) = E\left(\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2\right) = \frac{n-1}{n} \cdot \text{Var}(X)$
- ▶ 样本方差  $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$
- ▶  $E(S^2) = E\left(\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2\right) = \text{Var}(X)$
- ▶ 样本方差  $S^2$  是  $\text{Var}(X)$  的无偏估计量
- ▶ 二阶中心矩  $B_2$  是  $\text{Var}(X)$  的渐进无偏估计量

## 2. 点估计

- ▶ 总体  $X \sim N(\mu, \sigma^2)$ 。判断  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$  和  $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$  的独立性。
- ▶ 考虑正交矩阵  $U$ ，第一行每个元素均为  $\frac{1}{\sqrt{n}}$ ，其余行任取
- ▶ 令随机向量  $\mathbf{X} = (X_1, X_2, \dots, X_n)$ ，令  $\mathbf{Y} = U\mathbf{X}$ ，注意  $\mathbf{Y}$  服从  $n$  维高斯分布，且有
  - ▶  $E(\mathbf{Y}) = (\sqrt{n}\mu, 0, 0, \dots, 0)$
  - ▶  $\text{Cov}(\mathbf{Y}) = \sigma^2 \cdot I$
  - ▶  $\sum_{i=1}^n Y_i^2 = \sum_{i=1}^n X_i^2$
- ▶  $\bar{X} = Y_1/\sqrt{n}$
- ▶  $(n-1)S^2 = \sum_{i=1}^n (X_i - \bar{X})^2 = (\sum_{i=1}^n X_i^2) - n\bar{X}^2 = (\sum_{i=1}^n Y_i^2) - Y_1^2 = \sum_{i=2}^n Y_i^2$
- ▶  $\text{Cov}(\mathbf{Y}) = \sigma^2 \cdot I \Rightarrow Y_i$  相互独立，因此  $\bar{X}$  与  $(n-1)S^2$  相互独立
- ▶  $\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$ 。 $\frac{(n-1)S^2}{\sigma^2}$  服从何种分布？

## 2. 点估计

- ▶  $(n-1)S^2 = \sum_{i=2}^n Y_i^2 \Rightarrow \frac{(n-1)S^2}{\sigma^2} = \sum_{i=2}^n \left(\frac{Y_i}{\sigma}\right)^2$
- ▶  $Y_i$  相互独立且对于  $i \geq 2$ ,  $Y_i \sim N(0, \sigma^2)$
- ▶ 若  $Z_1, Z_2, \dots, Z_n$  独立同分布且  $Z_i \sim N(0, 1)$ , 则  $\sum_{i=1}^n Z_i^2 \sim \chi^2(n)$ 
  - ▶ 由作业三,  $Z_i^2 \sim \chi^2(1)$ , 也即  $Z_i^2 \sim \Gamma\left(\frac{1}{2}, \frac{1}{2}\right)$
  - ▶ 因此  $\sum_{i=1}^n Z_i^2 \sim \Gamma\left(\frac{n}{2}, \frac{1}{2}\right)$
- ▶ 因此有  $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$

## 2. 点估计

- ▶ **点估计**：估计分布中所含有的未知参数 $\theta$ 
  - ▶ 已知总体 $X \sim U(0, \theta)$ , 估计 $\theta$
  - ▶ 已知总体 $X \sim N(\mu, \sigma^2)$ , 估计 $\mu$ 和 $\sigma^2$
- ▶ **估计量**：用来估计未知参数 $\theta$ 的统计量 $\hat{\theta}(X_1, X_2, \dots, X_n)$
- ▶ 设计估计量的常用方法
  - ▶ 矩法
  - ▶ 最大似然估计

## 2. 点估计

- ▶ 矩法：用样本矩去替换总体矩
- ▶ 1. 将未知参数 $\theta_1, \theta_2, \dots, \theta_k$ 表示为总体前 $k$ 阶矩的函数
  - ▶  $\theta_i = f_i(\mu_1, \mu_2, \dots, \mu_k)$
  - ▶  $\mu_i$ 是总体 $X$ 的 $i$ 阶原点矩 $E(X^i)$ 或 $i$ 阶中心矩 $E((X - E(X))^i)$
- ▶ 2. 用样本的 $i$ 阶矩或 $i$ 阶中心矩替换 $\mu_i$ 
  - ▶  $\hat{\theta}_i = f_i(A_1, A_2, \dots, A_k)$ 或 $\hat{\theta}_i = f_i(B_1, B_2, \dots, B_k)$
  - ▶  $k$ 阶矩： $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$
  - ▶  $k$ 阶中心矩： $B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$
- ▶ 也可以用样本方差 $S^2$ 替换 $\text{Var}(X)$

## 2. 点估计

- ▶ 矩法：用样本矩去替换总体矩
- ▶ 例1：已知总体  $X \sim U(0, \theta)$ 。用矩法设计  $\theta$  的估计量
  - ▶  $\theta = 2E(X) \Rightarrow \hat{\theta}(X_1, X_2, \dots, X_n) = 2\bar{X}$
- ▶ 例2：已知总体  $X \sim U(a, b)$ 。用矩法设计  $a$  和  $b$  的估计量
  - ▶  $a + b = 2E(X)$
  - ▶  $\text{Var}(X) = \frac{(b-a)^2}{12} \Rightarrow b - a = \sqrt{12 \cdot \text{Var}(X)}$
  - ▶  $a = E(X) - \sqrt{3 \cdot \text{Var}(X)}, b = E(X) + \sqrt{3 \cdot \text{Var}(X)}$
  - ▶  $\hat{a} = \bar{X} - \sqrt{3 \cdot S^2}, \hat{b} = \bar{X} + \sqrt{3 \cdot S^2}$

## 2. 点估计

► 例3: 已知总体  $X \sim \text{Exp}(\lambda)$ 。用矩法设计  $\lambda$  的估计量

►  $E(X) = \frac{1}{\lambda} \Rightarrow \hat{\lambda} = \frac{1}{\bar{X}}$

►  $\text{Var}(X) = \frac{1}{\lambda^2} \Rightarrow \hat{\lambda} = \frac{1}{\sqrt{S^2}}$

► 例4: 已知总体  $X \sim N(\mu, \sigma^2)$ 。用矩法设计  $\mu$  和  $\sigma^2$  的估计量

►  $\mu = E(X), \sigma^2 = \text{Var}(X) \Rightarrow \hat{\mu} = \bar{X}, \hat{\sigma}^2 = S^2$  或  $\hat{\sigma}^2 = B_2$

►  $\mu = E(X), E(X^2) = \mu^2 + \sigma^2 \Rightarrow \hat{\mu} = \bar{X}, \hat{\sigma}^2 = A_2 - \bar{X}^2$



## 2. 点估计

- ▶ 例4: 已知总体  $X \sim N(\mu, \sigma^2)$ 。用矩法设计  $\mu$  和  $\sigma^2$  的估计量
- ▶  $\sigma^2$  的估计量:  $S^2$ ,  $B_2$ ,  $A_2 - \bar{X}^2$
- ▶ 比较三者的均方误差?
- ▶  $B_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - (\bar{X})^2 = A_2 - \bar{X}^2$
- ▶  $\text{MSE}(S^2) = \text{Var}(S^2)$ , 而  $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$ ,
- ▶  $\text{MSE}(S^2) = \text{Var}(S^2) = \frac{2(n-1)}{(n-1)^2} \cdot \sigma^4 = \frac{2}{n-1} \cdot \sigma^4$
- ▶  $\text{MSE}(B_2) = E((B_2 - \sigma^2)^2) = E(B_2^2) + \sigma^4 - 2\sigma^2 E(B_2)$
- ▶  $E(B_2^2) = \left(\frac{n-1}{n}\right)^2 \cdot E((S^2)^2) = \left(\frac{n-1}{n}\right)^2 \cdot \frac{\sigma^4}{(n-1)^2} \cdot ((n-1)^2 + 2(n-1)) = \frac{n^2-1}{n^2} \cdot \sigma^4$
- ▶  $E(B_2) = \frac{\sigma^2(n-1)}{n} \Rightarrow \text{MSE}(B_2) = \frac{2n-1}{n^2} \sigma^4$

## 2. 点估计

- ▶ 例5：从 $\{1, 2, \dots, N\}$ 中等概率且不放回地抽取  $n$  个样本。设计  $N$  的估计量
- ▶  $X_1, X_2, \dots, X_n$  不独立，不符合简单随机样本的情况
- ▶  $E(X) = \frac{N+1}{2} \Rightarrow \hat{N} = 2\bar{X} - 1$
- ▶ 判断  $\hat{N} = 2\bar{X} - 1$  的无偏性，并计算  $\hat{N}$  的均方误差

## 2. 点估计

- ▶  $\hat{N} = \frac{2(X_1 + X_2 + \cdots + X_n)}{n} - 1$
- ▶ 如何计算  $E(X_i)$ ?
  - ▶  $P(X_i = k) = \frac{1}{N} \Rightarrow E(X_i) = \frac{N+1}{2}$
- ▶  $E(\hat{N}) = N$ ,  $\hat{N}$  是无偏估计量
- ▶  $\text{MSE}(\hat{N}) = \text{Var}(\hat{N}) = 4\text{Var}(\bar{X}) = \frac{4}{n^2} \cdot \text{Var}(X_1 + X_2 + \cdots + X_n)$
- ▶  $\text{Var}(X_i) = \frac{N^2-1}{12}$ ,  $\text{Cov}(X_i, X_j) = -\frac{N+1}{12}$
- ▶  $\text{MSE}(\hat{N}) = \frac{1}{3n}(N+1)(N-n)$

## 2. 点估计

- ▶ **点估计**: 给定样本  $x_1, x_2, \dots, x_n$ , 估计分布中所含有的未知参数  $\theta$
- ▶ **最大似然估计**: 选择参数  $\theta$ , 使得**似然函数**  $L(\theta) = P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n; \theta)$ 最大
- ▶ **最大似然估计量**: 满足  $L(\hat{\theta}) = \max_{\theta} L(\theta)$  的统计量  $\hat{\theta}$
  
- ▶ 例1: 已知某网站不同用户点击广告的情况服从参数为  $p$  的伯努利分布。给定简单随机样本  $x_1, x_2, \dots, x_n \in \{0, 1\}$ , 求未知参数  $p$  的最大似然估计。

## 2. 点估计

- ▶ **最大似然估计**: 选择参数 $\theta$ , 使得**似然函数**  $L(\theta) = P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n; \theta)$ 最大
- ▶ 例1: 已知某网站不同用户点击广告的情况服从参数为 $p$ 的伯努利分布。给定简单随机样本 $x_1, x_2, \dots, x_n \in \{0, 1\}$ , 求未知参数 $p$ 的最大似然估计。
- ▶  $P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n; p) = \prod_{i=1}^n p^{x_i}(1-p)^{1-x_i} = p^{\sum x_i}(1-p)^{n-\sum x_i}$
- ▶ 选择  $p$  最大化  $P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n; p)$
- ▶ 对  $p$  求导,  $\sum x_i \cdot p^{\sum x_i - 1}(1-p)^{n-\sum x_i} - (n - \sum x_i) \cdot p^{\sum x_i}(1-p)^{n-\sum x_i - 1} = 0$
- ▶  $\sum x_i(1-p) - (n - \sum x_i) \cdot p = 0 \Rightarrow p = \sum x_i / n$
- ▶  $\hat{p}_{\text{MLE}} = \bar{X}$

## 2. 点估计

- ▶ **最大似然估计 (MLE)** : 选择参数 $\theta$ , 使得**似然函数**  $L(\theta) = P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n; \theta)$ 最大
- ▶ 例2: 某超算中心每日收到的任务数量服从 $\pi(\lambda)$ 。给定简单随机样本 $x_1, x_2, \dots, x_n$ , 求未知参数 $\lambda$ 的最大似然估计。
  - ▶  $P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n; \lambda) = \prod_{i=1}^n \frac{e^{-\lambda} \lambda^{x_i}}{x_i!} = \frac{e^{-n\lambda} \lambda^{\sum x_i}}{\prod x_i!}$
  - ▶ 选择  $p$  最大化  $P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n; \lambda)$
  - ▶ 求导,  $e^{-n\lambda} \lambda^{\sum x_i - 1} \cdot \sum x_i - n \cdot e^{-n\lambda} \lambda^{\sum x_i} = 0 \Rightarrow \lambda = \sum x_i / n$
  - ▶  $\hat{\lambda}_{\text{MLE}} = \bar{X}$

## 2. 点估计

- ▶ **最大似然估计 (MLE)** : 选择参数 $\theta$ , 使得**似然函数**  $L(\theta) = P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n; \theta)$ 最大
- ▶ 对于简单随机样本,  $P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n; \theta) = \prod_{i=1}^n P(X_i = x_i; \theta)$
- ▶ 最大化 $L(\theta)$ 等价于最大化**对数似然函数**  $\ln L(\theta) = \sum_{i=1}^n \ln P(X_i = x_i; \theta)$
- ▶ 例2: 某超算中心每日收到的任务数量服从 $\pi(\lambda)$ 。给定简单随机样本 $x_1, x_2, \dots, x_n$ , 求未知参数 $\lambda$ 的最大似然估计。
- ▶  $\ln L(\lambda) = \sum_{i=1}^n \ln P(X_i = x_i; \lambda) = \sum_{i=1}^n (-\lambda + x_i \ln \lambda - \ln(x_i!))$
- ▶ 对 $\lambda$ 求导,  $-n + \frac{\sum x_i}{\lambda} = 0 \Rightarrow \lambda = \sum x_i / n$

## 2. 点估计

- ▶ 当总体 $X$ 为连续型, 定义**似然函数** $L(\theta) = f(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n; \theta)$
- ▶ **最大似然估计 (MLE)**: 选择参数 $\theta$ , 使得**似然函数** $L(\theta) = f(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n; \theta)$ 最大
- ▶ 例3: 令总体 $X$ 服从 $U(0, \theta)$ 。给定简单随机样本 $x_1, x_2, \dots, x_n$ , 求未知参数 $\theta$ 的最大似然估计。
- ▶ 
$$L(\theta) = \prod_{i=1}^n \frac{1_{x_i \leq \theta}}{\theta} = \frac{1_{x_1 \leq \theta, x_2 \leq \theta, \dots, x_n \leq \theta}}{\theta^n}$$
- ▶ 最大化  $L(\theta) \Rightarrow \theta = \max\{x_1, x_2, \dots, x_n\}$



## 2. 点估计

- ▶ 当总体 $X$ 为连续型, 定义**似然函数** $L(\theta) = f(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n; \theta)$
- ▶ **最大似然估计 (MLE)**: 选择参数 $\theta$ , 使得**似然函数** $L(\theta) = f(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n; \theta)$ 最大
- ▶ 例4: 令总体 $X$ 服从 $N(\mu, \sigma^2)$ 。给定简单随机样本 $x_1, x_2, \dots, x_n$ , 求未知参数 $\mu$ 的和 $\sigma^2$ 最大似然估计。
- ▶ 
$$\ln L(\mu, \sigma^2) = \sum_{i=1}^n \ln \left( \frac{1}{\sqrt{2\pi} \cdot \sigma} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}} \right) = \sum_{i=1}^n \left( -\frac{(x_i - \mu)^2}{2\sigma^2} - \frac{\ln \sigma^2}{2} - \frac{\ln 2\pi}{2} \right)$$
- ▶ 
$$\frac{\partial \ln L(\mu, \sigma^2)}{\partial \mu} = 0 \Rightarrow \mu = \frac{\sum x_i}{n} = \bar{X}$$
- ▶ 
$$\frac{\partial \ln L(\mu, \sigma^2)}{\partial \sigma^2} = 0 \Rightarrow \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^4} - \frac{n}{2\sigma^2} = 0 \Rightarrow \sigma^2 = \frac{1}{n} \cdot \sum_{i=1}^n (x_i - \mu)^2 = B_2$$

## 2. 点估计

- ▶ 例4：令总体 $X$ 服从 $N(\mu, \sigma^2)$ 。给定简单随机样本 $x_1, x_2, \dots, x_n$ ，求未知参数 $\mu$ 的和 $\sigma^2$ 最大似然估计。
- ▶  $\hat{\mu}_{\text{MLE}} = \frac{\sum x_i}{n} = \bar{X}$
- ▶  $\widehat{\sigma^2}_{\text{MLE}} = \frac{1}{n} \cdot \sum_{i=1}^n \left( x_i - \frac{\sum x_i}{n} \right)^2 = B_2$
- ▶ 如何求 $\sigma$ 的最大似然估计？
  - ▶  $\hat{\sigma}_{\text{MLE}} = \sqrt{B_2}$
- ▶ 最大似然估计的不变性：给定 $\theta$ 的最大似然估计 $\hat{\theta}$ 。若 $g(\theta)$ 有单值反函数，则 $g(\theta)$ 的最大似然估计为 $g(\hat{\theta})$ 。

## 2. 点估计



- ▶ 当总体 $X$ 为连续型, 定义**似然函数** $L(\theta) = f(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n; \theta)$
- ▶ **最大似然估计 (MLE)**: 选择参数 $\theta$ , 使得**似然函数** $L(\theta) = f(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n; \theta)$ 最大
- ▶ 例5: 总体 $X$ 的概率密度函数为
  - ▶  $f(x) = \frac{1}{\theta} \cdot e^{-(x-\mu)/\theta}$  若  $x \geq \mu$
  - ▶ 否则  $f(x) = 0$
- ▶ 给定简单随机样本 $x_1, x_2, \dots, x_n$ , 求未知参数 $\mu$ 和 $\theta$ 的最大似然估计和矩法估计。
- ▶ 矩法:  $X - \mu \sim \text{Exp}\left(\frac{1}{\theta}\right) \Rightarrow E(X) = \mu + \theta, \text{Var}(X) = \theta^2$
- ▶  $\hat{\theta} = \sqrt{B_2}, \mu = \bar{X} - \sqrt{B_2}$

## 2. 点估计

- ▶ 例5：总体 $X$ 的概率密度函数为
  - ▶  $f(x) = \frac{1}{\theta} \cdot e^{-(x-\mu)/\theta}$  若  $x \geq \mu$
  - ▶ 否则  $f(x) = 0$
- ▶ 给定简单随机样本 $x_1, x_2, \dots, x_n$ ，求未知参数 $\mu$ 和 $\theta$ 的最大似然估计和矩法估计。
- ▶  $L(\mu, \theta) = \frac{1}{\theta^n} \cdot e^{-\frac{1}{\theta} \sum (x_i - \mu)} \cdot 1_{x_1 \geq \mu, x_2 \geq \mu, \dots, x_n \geq \mu}$
- ▶ 当  $x_1 \geq \mu, x_2 \geq \mu, \dots, x_n \geq \mu$ ， $L(\mu, \theta)$ 关于  $\mu$ 为增函数
- ▶  $\hat{\mu}_{\text{MLE}} = \min\{x_1, x_2, \dots, x_n\}$
- ▶  $\ln L(\mu, \theta) = -n \ln \theta - \frac{1}{\theta} \sum (x_i - \mu)$
- ▶ 求导， $-\frac{n}{\theta} + \frac{1}{\theta^2} \sum (x_i - \mu) = 0 \Rightarrow \hat{\theta}_{\text{MLE}} = \bar{X} - \mu = \bar{X} - \min\{x_1, x_2, \dots, x_n\}$

## 2. 点估计

- ▶ **最大似然估计**: 选择参数 $\theta$ , 使得**似然函数**  $L(\theta) = P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n; \theta)$ 最大
- ▶ **分类问题**: 给定数据 $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ 。其中 $x_i \in \mathcal{X}$ 为数据,  $y_i \in \{1, 2, \dots, C\}$ 为分类标签。利用数据学习分类函数 $f: \mathcal{X} \rightarrow \{1, 2, \dots, C\}$ 。



## 2. 点估计

- ▶ **分类问题**: 给定数据  $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ 。利用数据学习分类函数  $f: \mathcal{X} \rightarrow \{1, 2, \dots, C\}$ 。
- ▶ **机器学习模型**: 给定参数  $\theta$ , 对于给定的数据  $x \in \mathcal{X}$ , 模型  $f_\theta$  输出  $\{1, 2, \dots, C\}$  上的一个分布
- ▶  $f_\theta(y|x)$  表示给定输入数据  $x \in \mathcal{X}$ , 分类为  $y$  的概率
- ▶ 分类函数:  $\operatorname{argmax}_y f_\theta(y|x)$
- ▶ 给定数据  $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ , 如何选取参数  $\theta$ ?

## 2. 点估计

- ▶ **最大似然估计**: 选择参数 $\theta$ , 使得**似然函数**  $L(\theta) = P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n; \theta)$ 最大
- ▶ **分类问题**: 给定数据 $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ 。利用数据学习分类函数 $f: \mathcal{X} \rightarrow \{1, 2, \dots, C\}$ 。
- ▶ **机器学习模型**: 给定参数 $\theta$ , 对于给定的数据 $x \in \mathcal{X}$ , 模型 $f_\theta$ 输出 $\{1, 2, \dots, C\}$ 上的一个分布
- ▶ 对于分类问题: 最大化似然函数 $L(\theta) = \prod_{i=1}^n f_\theta(y_i | x_i)$
- ▶ 实践中, 通常改为最小化 $-\ln L(\theta) = \sum_{i=1}^n -\ln f_\theta(y_i | x_i)$

## 2. 点估计

- ▶ 对于两个分布  $p$  和  $q$ , 定义**交叉熵**  $H(p, q) = -E_p(\ln q)$ 
  - ▶ 对于离散分布,  $H(p, q) = -\sum_x p(x) \ln q(x)$
  - ▶ 对于连续分布,  $H(p, q) = -\int P(x) \ln Q(x) dx$ ,  $P(x)$  和  $Q(x)$  为概率密度函数
- ▶  $p$  为数据真实标签对应的分布, 也即  $p(y|x_i) = 1_{y=y_i}$
- ▶  $-\ln L(\theta) = \sum_{i=1}^n -\ln f_{\theta}(y_i|x_i) = \sum_{i=1}^n H_i(p, f_{\theta})$ 
  - ▶  $H_i$  为数据  $x_i$  真实标签分布和模型输出分布的交叉熵
  - ▶  $H_i(p, f_{\theta}) = -\sum_y p(y|x_i) \ln f_{\theta}(y|x_i) = -\ln f_{\theta}(y_i|x_i)$
- ▶ 结论: 在分类问题中, 最大似然估计等价于最小化交叉熵损失函数



## 2. 点估计

- ▶ **机器学习模型**: 给定参数 $\theta$ , 对于给定的数据 $x \in \mathcal{X}$ , 模型 $f_\theta$ 输出 $\{1, 2, \dots, C\}$ 上的一个分布
  - ▶ 满足 $f_\theta(y|x) \geq 0$ 和 $\sum_y f_\theta(y|x) = 1$
- ▶ 如何放松上述要求?
- ▶  $\text{softmax}_i(a_1, a_2, \dots, a_C) = \frac{e^{a_i}}{\sum_j e^{a_j}}$
- ▶ 给定 $f_\theta: \mathcal{X} \rightarrow \mathbb{R}^C$ , 将softmax应用于 $f_\theta$ 的输出即可得到 $\{1, 2, \dots, C\}$ 上的分布
- ▶ 实践中, 交叉熵损失函数往往与softmax配合使用

### 3. 区间估计

- ▶ **点估计**: 给定样本  $x_1, x_2, \dots, x_n$ , 估计分布中所含有的未知参数  $\theta$
- ▶ **区间估计**: 设计统计量  $\hat{\theta}_L(X_1, X_2, \dots, X_n)$  和  $\hat{\theta}_U(X_1, X_2, \dots, X_n)$ , 使得  $\theta \in [\hat{\theta}_L, \hat{\theta}_U]$  的概率尽量大
- ▶  $P(\theta \in [\hat{\theta}_L, \hat{\theta}_U])$  越大, 则导致区间长度  $\hat{\theta}_U - \hat{\theta}_L$  更长
- ▶ **置信区间**: 若统计量  $\hat{\theta}_L(X_1, X_2, \dots, X_n)$  和  $\hat{\theta}_U(X_1, X_2, \dots, X_n)$ , 对于任意  $\theta$ , 满足  $P(\hat{\theta}_L \leq \theta \leq \hat{\theta}_U) \geq 1 - \alpha$ , 则  $[\hat{\theta}_L, \hat{\theta}_U]$  为  $\theta$  的**置信水平**为  $1 - \alpha$  的**置信区间**.
  - ▶  $\hat{\theta}_L$ : 置信下限
  - ▶  $\hat{\theta}_U$ : 置信上限

### 3. 区间估计

- ▶ **置信区间**: 若统计量  $\hat{\theta}_L(X_1, X_2, \dots, X_n)$  和  $\hat{\theta}_U(X_1, X_2, \dots, X_n)$ , 对于任意  $\theta$ , 满足  $P(\hat{\theta}_L \leq \theta \leq \hat{\theta}_U) \geq 1 - \alpha$ , 则  $[\hat{\theta}_L, \hat{\theta}_U]$  为  $\theta$  的**置信水平**为  $1 - \alpha$  的**置信区间**。
- ▶ **单侧置信下限**: 若统计量  $\hat{\theta}_L(X_1, X_2, \dots, X_n)$ , 对于任意  $\theta$ , 满足  $P(\hat{\theta}_L \leq \theta) \geq 1 - \alpha$ , 则  $\hat{\theta}_L$  为  $\theta$  的**置信水平**为  $1 - \alpha$  的**单侧置信下限**。
- ▶ **单侧置信上限**: 若统计量  $\hat{\theta}_U(X_1, X_2, \dots, X_n)$ , 对于任意  $\theta$ , 满足  $P(\theta \leq \hat{\theta}_U) \geq 1 - \alpha$ , 则  $\hat{\theta}_U$  为  $\theta$  的**置信水平**为  $1 - \alpha$  的**单侧置信上限**。
- ▶ 若  $\hat{\theta}_L$  为  $\theta$  的置信水平为  $1 - \alpha_1$  的单侧置信下限,  $\hat{\theta}_U$  为  $\theta$  的置信水平为  $1 - \alpha_2$  的单侧置信上限, 则  $[\hat{\theta}_L, \hat{\theta}_U]$  为  $\theta$  的置信水平为  $1 - \alpha_1 - \alpha_2$  的置信区间。

### 3. 区间估计

- ▶ 例1: 总体  $X \sim N(\mu, \sigma^2)$ ,  $\sigma^2$  已知。设计  $\mu$  的置信水平为  $1 - \alpha$  的置信区间
- ▶ 利用  $\bar{X}$  构造置信区间?
- ▶ 注意到  $\bar{X} \sim N(\mu, \sigma^2/n)$ , 也即  $\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$
- ▶  $P\left(c \leq \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \leq d\right) = 1 - \alpha \Rightarrow P\left(\bar{X} - \frac{d\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} - \frac{c\sigma}{\sqrt{n}}\right) = 1 - \alpha$
- ▶ 如何选择  $c$  与  $d$  使得区间最短?
  - ▶ 令  $\Phi(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt$  为标准正态分布的分布函数
  - ▶ 取  $c = \Phi^{-1}(\alpha/2)$ ,  $d = \Phi^{-1}(1 - \alpha/2)$ , 注意到  $c + d = 0$
- ▶ 结论:  $P\left(\bar{X} - \frac{\Phi^{-1}(1-\alpha/2) \cdot \sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + \frac{\Phi^{-1}(1-\alpha/2) \cdot \sigma}{\sqrt{n}}\right) = 1 - \alpha$

### 3. 区间估计

- ▶ 例1: 总体  $X \sim N(\mu, \sigma^2)$ ,  $\sigma^2$  已知。设计  $\mu$  的置信水平为  $1 - \alpha$  的置信区间
- ▶  $\bar{X}$  为无偏估计量。基于集中不等式构造置信区间?
- ▶ 回顾: 若  $X \sim N(\mu, \sigma^2)$ 
  - ▶  $P(X - E(X) \geq k\sigma) \leq e^{-\frac{k^2}{2}}$
  - ▶  $P(X - E(X) \leq -k\sigma) \leq e^{-\frac{k^2}{2}}$
- ▶  $\bar{X} - \mu \sim N(0, \sigma^2/n) \Rightarrow P\left(|\bar{X} - \mu| \geq \frac{k\sigma}{\sqrt{n}}\right) \leq 2e^{-\frac{k^2}{2}}$
- ▶  $2e^{-\frac{k^2}{2}} = \alpha \Rightarrow k = \sqrt{2\ln(2/\alpha)}$
- ▶ 结论:  $P\left(\bar{X} - \frac{\sigma \cdot \sqrt{2\ln(2/\alpha)}}{\sqrt{n}} \leq \mu \leq \bar{X} + \frac{\sigma \cdot \sqrt{2\ln(2/\alpha)}}{\sqrt{n}}\right) \leq 1 - \alpha$
- ▶ 与  $P\left(\bar{X} - \frac{\Phi^{-1}(1-\alpha/2) \cdot \sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + \frac{\Phi^{-1}(1-\alpha/2) \cdot \sigma}{\sqrt{n}}\right) = 1 - \alpha$  的联系?

### 3. 区间估计

- ▶ **置信区间**: 若统计量 $\hat{\theta}_L(X_1, X_2, \dots, X_n)$ 和 $\hat{\theta}_U(X_1, X_2, \dots, X_n)$ , 对于任意 $\theta$ 满足 $P(\hat{\theta}_L \leq \theta \leq \hat{\theta}_U) \geq 1 - \alpha$ , 则 $[\hat{\theta}_L, \hat{\theta}_U]$ 为 $\theta$ 的**置信水平**为 $1 - \alpha$ 的**置信区间**.
- ▶ **枢轴量法**
  - ▶ 1. 设计枢轴量 $G = G(x_1, x_2, \dots, x_n)$ , 使得 $G$ 的分布与未知参数 $\theta$ 无关。
  - ▶ 2. 选择 $c$ 和 $d$ ,  $P(c \leq G \leq d) = 1 - \alpha$ ,  $c \leq G \leq d$ 可变形为 $\hat{\theta}_L \leq \theta \leq \hat{\theta}_U$
  - ▶ 3. 得到结论 $P(\hat{\theta}_L \leq \theta \leq \hat{\theta}_U) = 1 - \alpha$
- ▶ 设计枢轴量通常从 $\theta$ 的点估计出发
- ▶ 通常选择 $c$ 和 $d$ 使得  $P(G < c) = P(G > d) = \alpha/2$

### 3. 区间估计

- ▶ 例2: 总体  $X \sim U(0, \theta)$ 。设计  $\theta$  的置信水平为  $1 - \alpha$  的置信区间。
- ▶ 令  $\hat{\theta} = \max\{X_1, X_2, \dots, X_n\}$  为  $\theta$  的最大似然估计
- ▶  $F_{\hat{\theta}}(x) = (F_X(x))^n = \left(\frac{x}{\theta}\right)^n$  当  $0 \leq x \leq \theta$
- ▶ 枢轴量  $G = \hat{\theta}/\theta$
- ▶  $F_G(x) = x^n$  当  $0 \leq x \leq 1$
- ▶  $P(c \leq G \leq d) = 1 - \alpha \Rightarrow P\left(\frac{\hat{\theta}}{d} \leq \theta \leq \frac{\hat{\theta}}{c}\right) = 1 - \alpha$
- ▶  $d^n - c^n = 1 - \alpha \Rightarrow d = 1, c = \alpha^{1/n}$
- ▶ 结论:  $P(\hat{\theta} \leq \theta \leq \hat{\theta} \cdot \alpha^{-1/n}) = 1 - \alpha$

### 3. 区间估计

- ▶ 例3：总体  $X \sim N(\mu, \sigma^2)$ 。设计  $\sigma^2$  的置信水平为  $1 - \alpha$  的置信区间。
- ▶ 回顾：  $S^2$  是  $\sigma^2$  的无偏估计，  $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$
- ▶ 令  $F(x)$  为  $\chi^2(n-1)$  的分布函数，取  $c = F^{-1}(\alpha/2)$ ,  $d = F^{-1}(1 - \alpha/2)$
- ▶ 则有  $P\left(c \leq \frac{(n-1)S^2}{\sigma^2} \leq d\right) = 1 - \alpha \Rightarrow P\left(\frac{(n-1)S^2}{d} \leq \sigma^2 \leq \frac{(n-1)S^2}{c}\right) = 1 - \alpha$



### 3. 区间估计

- ▶ 例4：总体  $X \sim N(\mu, \sigma^2)$ ,  $\mu, \sigma^2$  均为未知参数。设计  $\mu$  的置信水平为  $1 - \alpha$  的置信区间。
- ▶  $\frac{\bar{X} - \mu}{\sqrt{S^2}}$  服从何种分布？
- ▶ 回顾：  $\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$ ,  $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$ , 且  $\bar{X}$  和  $S^2$  相互独立
- ▶ **t分布**：令  $X_1 \sim N(0, 1)$ ,  $X_2 \sim \chi^2(n)$ ,  $X_1$  和  $X_2$  相互独立。称  $T = \frac{X_1}{\sqrt{X_2/n}}$  的分布为自由度为  $n$  的 **t分布**, 记为  $T \sim t(n)$


### 3. 区间估计

- ▶  **$t$ 分布**: 令  $X_1 \sim N(0,1)$ ,  $X_2 \sim \chi^2(n)$ ,  $X_1$ 和 $X_2$ 相互独立。称  $T = \frac{X_1}{\sqrt{X_2/n}}$  的分布为自由度为 $n$ 的 **$t$ 分布**, 记为  $T \sim t(n)$

- ▶ 自由度为 $n$ 的 $t$ 分布概率密度函数: 
$$f(t) = \frac{\Gamma(\frac{n+1}{2})}{\sqrt{n\pi}\Gamma(\frac{n}{2})} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}}$$

- ▶ 当  $n = 1$ ,  $f(t) = \frac{1}{1+t^2} \cdot \frac{1}{\pi}$

- ▶ 当自由度 $n$ 较大, 近似为标准正态分布



### 3. 区间估计

- ▶ 例4: 总体 $X \sim N(\mu, \sigma^2)$  且 $\mu, \sigma^2$ 均为未知参数。设计 $\mu$ 的置信水平为 $1 - \alpha$ 的置信区间。
- ▶ **t分布**: 令  $X_1 \sim N(0,1)$ ,  $X_2 \sim \chi^2(n)$ ,  $X_1$ 和 $X_2$ 相互独立。称 $T = \frac{X_1}{\sqrt{X_2/n}}$ 的分布为自由度为 $n$ 的**t分布**, 记为 $T \sim t(n)$
- ▶ 回顾:  $\frac{\bar{X}-\mu}{\sigma/\sqrt{n}} \sim N(0, 1)$ ,  $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$ , 且 $\bar{X}$ 和 $S^2$ 相互独立
- ▶  $\frac{\sqrt{n}(\bar{X}-\mu)}{\sqrt{S^2}} \sim t(n-1)$
- ▶  $P\left(c \leq \frac{\sqrt{n}(\bar{X}-\mu)}{\sqrt{S^2}} \leq d\right) = 1 - \alpha \Rightarrow P\left(\bar{X} - d \cdot \frac{\sqrt{S^2}}{\sqrt{n}} \leq \mu \leq \bar{X} - c \cdot \frac{\sqrt{S^2}}{\sqrt{n}}\right) = 1 - \alpha$
- ▶ 令 $F(x)$ 为 $t(n-1)$ 的分布函数, 取 $c = F^{-1}(\alpha/2)$ ,  $d = F^{-1}(1 - \alpha/2)$
- ▶ 注意到 $c + d = 0$

### 3. 区间估计

▶ 例5：总体  $X \sim B(1, p)$ 。设计  $p$  的置信水平为  $1 - \alpha$  的置信区间。

▶ 由中心极限定理,  $\frac{\sum_{i=1}^n X_i - np}{\sqrt{np(1-p)}}$  近似服从  $N(0, 1)$

▶  $P\left(-\Phi^{-1}\left(1 - \frac{\alpha}{2}\right) \leq \frac{\sum_{i=1}^n X_i - np}{\sqrt{np(1-p)}} \leq \Phi^{-1}\left(1 - \frac{\alpha}{2}\right)\right) \approx 1 - \alpha$

▶  $\Phi(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx$  为标准正态分布的分布函数

▶ 解方程可得到置信水平为  $1 - \alpha$  的近似置信区间

### 3. 区间估计

- ▶ 例5: 总体  $X \sim B(1, p)$ 。设计  $p$  的置信水平为  $1 - \alpha$  的置信区间。
- ▶  $\bar{X}$  为无偏估计
- ▶ Chernoff bound:  $P(|\bar{X} - p| > \epsilon) \leq 2e^{-2n\epsilon^2}$
- ▶  $2 \cdot e^{-2n\epsilon^2} = \alpha \Rightarrow \epsilon = \sqrt{\ln(2/\alpha) / 2n}$
- ▶  $P(\bar{X} - \sqrt{\ln(2/\alpha) / 2n} \leq p \leq \bar{X} + \sqrt{\ln(2/\alpha) / 2n}) \geq 1 - \alpha$

### 3. 区间估计

- ▶ 有 $n$ 台游戏机，第 $i$ 台游戏机中奖概率为未知参数 $p_i$ 。
- ▶ 每一轮可从 $n$ 台游戏机选择一台并进行游戏
- ▶ 用最少的轮数，找到中奖概率最高的游戏机
- ▶ 应用：推荐系统，医疗， ...
- ▶ 第 $t$ 轮中：
  - ▶ 选择游戏机 $i$
  - ▶ 观测到结果  $X_t \sim B(1, p_i)$
- ▶ 输出：中奖概率最高的游戏机  $o \in \{1, 2, \dots, n\}$
- ▶ 均匀采样：对每台游戏机采集相同数量的样本 $N$ ，返回样本均值最大的游戏机
- ▶ 要求：返回游戏机  $o \in \{1, 2, \dots, n\}$ ，使得  $P(p_o \geq \max_i p_i - \epsilon) \geq 2/3$ 。  $N$  应当取多大？



### 3. 区间估计

- ▶ 若对第 $i$ 台游戏机采集 $N$ 个样本
- ▶  $P(\bar{X}_i - \sqrt{\ln(2/\alpha)/2N} \leq p_i \leq \bar{X}_i + \sqrt{\ln(2/\alpha)/2N}) \geq 1 - \alpha$
- ▶ 若取  $N = O(\ln(1/\alpha)/\epsilon^2)$ , 则有  $P(|p_i - \bar{X}_i| \leq \epsilon) \geq 1 - \alpha$
- ▶  $\alpha$ 应当如何选择?
- ▶ 取  $\alpha = \frac{1}{3n}$ ,  $N = O(\ln n / \epsilon^2)$ , 则  $P(|p_i - \bar{X}_i| \leq \epsilon) \geq 1 - \frac{1}{3n}$
- ▶ Union bound:  $P(\forall i, |p_i - \bar{X}_i| \leq \epsilon) \geq 2/3$
- ▶ 此时, 样本均值最大的游戏机 $o$ 满足  $p_o \geq \max_i p_i - 2\epsilon$
- ▶  $p_o \geq \bar{X}_o - \epsilon \geq \bar{X}_i - \epsilon \geq p_i - 2\epsilon$

### 3. 区间估计

- ▶ 均匀采样：对每台游戏机采集相同数量的样本 $N$ ，返回样本均值最大的游戏机
- ▶ 如何使 $P(p_o \geq \max_i p_i - \epsilon) \geq 1 - \delta$ ?
- ▶  $P(\bar{X}_i - \sqrt{\ln(2/\alpha)/2N} \leq p_i \leq \bar{X}_i + \sqrt{\ln(2/\alpha)/2N}) \geq 1 - \alpha$
- ▶ 取 $\alpha = \delta/n$ ,  $N = O(\ln(n/\delta)/\epsilon^2)$ , 则 $P(|p_i - \bar{X}_i| \leq \epsilon) \geq 1 - \delta/n$
- ▶ Union bound:  $P(\forall i, |p_i - \bar{X}_i| \leq \epsilon) \geq 1 - \delta$
- ▶ 对每台游戏机采集样本数量:  $O(\ln(n/\delta)/\epsilon^2)$